

Progettazione di un'infrastruttura AI multi-cloud

Caso Energogrid S.p.A.

Strategia architetturale ad alto livello per la migrazione e l'operatività di workload AI verso una piattaforma ibrida multi-cloud, applicata al forecasting energetico, alla manutenzione predittiva degli asset e all'ottimizzazione del bilanciamento rete-produzione.

Autore Simone La Porta

Data 30/06/2026

Indice

Indice.....	2
Executive summary.....	4
1. Contesto e caso d'uso Energogrid.....	5
1.1 Profilo dell'azienda.....	5
1.2 Tre scenari predittivi.....	5
1.3 Requisiti funzionali.....	5
1.4 Requisiti non funzionali.....	6
2. Catalogo dei servizi considerati.....	7
2.1 PaaS AWS.....	7
2.2 PaaS Microsoft Azure.....	7
2.3 PaaS Google Cloud.....	8
2.4 Open-source e componenti on-prem.....	8
3. Criteri di valutazione comparativa.....	9
3.1 Costo (TCO 3-5 anni).....	9
3.2 Scalabilità e resilienza.....	10
3.3 Sicurezza e compliance.....	10
3.4 Portabilità e rischio di vendor lock-in.....	10
3.5 Operabilità e ciclo di vita ML.....	10
3.6 Ecosistema e integrazione.....	11
3.7 Supporto e comunità.....	11
3.8 Time-to-market e agilità.....	11
4. Analisi comparativa.....	11
4.1 Mappa di sintesi criteri x cluster.....	11
4.2 Pro e contro per cluster.....	12
4.2.1 AWS PaaS.....	12
4.2.2 Azure PaaS.....	12
4.2.3 GCP PaaS.....	13
4.2.4 OSS on-prem.....	13
4.2.5 Hybrid mix.....	13
5. Strategia architetturale concettuale.....	14
5.1 Principi guida.....	14
5.2 Componenti logici della piattaforma.....	14
5.3 Pattern di distribuzione dei workload.....	15
5.4 Modello di responsabilità multi-cloud.....	17

6. Impatto su processi e costi.....	18
6.1 <i>Impatto organizzativo.....</i>	<i>18</i>
6.2 <i>TCO concettuale a 5 anni.....</i>	<i>18</i>
7. Sicurezza, compliance e data governance.....	19
7.1 <i>Quadro normativo applicabile.....</i>	<i>20</i>
7.2 <i>Controlli per dominio.....</i>	<i>20</i>
7.3 <i>Data governance e lineage.....</i>	<i>21</i>
7.4 <i>Checklist di alto livello.....</i>	<i>21</i>
8. Piano di migrazione e roadmap.....	22
8.1 <i>Strategia incrementale a tre wave.....</i>	<i>22</i>
8.2 <i>Milestone e gate strategici.....</i>	<i>23</i>
8.3 <i>Rischi principali e mitigazioni.....</i>	<i>24</i>
9. KPI di progetto e misurazione.....	25
9.1 <i>KPI di business.....</i>	<i>25</i>
9.2 <i>KPI tecnici e operativi (MLOps).....</i>	<i>26</i>
9.3 <i>KPI di governance e compliance.....</i>	<i>26</i>
9.4 <i>Sistema di misurazione.....</i>	<i>26</i>
10. Conclusioni e raccomandazioni strategiche.....	27
10.1 <i>Sintesi delle scelte strategiche.....</i>	<i>27</i>
10.2 <i>Priorità raccomandate.....</i>	<i>28</i>
10.3 <i>Prossimi passi strategici.....</i>	<i>28</i>
Allegato A · Glossario.....	29
Allegato B · Riferimenti normativi.....	31

Executive summary

Energogrid S.p.A. è un operatore integrato del settore energetico che gestisce produzione tradizionale e rinnovabile, sistemi di stoccaggio e una rete di distribuzione intelligente. Le tre iniziative AI prioritarie - forecasting della domanda, manutenzione predittiva degli asset e ottimizzazione del bilanciamento - hanno ricaduta diretta su affidabilità della rete, costo del kilowattora consegnato e capacità di assorbire la variabilità delle rinnovabili. Tutte e tre condividono la stessa esigenza infrastrutturale: una piattaforma AI in grado di trattare dati di telemetria con vincoli stringenti di sovranità, di sostenere il ciclo di vita dei modelli su orizzonti pluriennali e di esporre previsioni sia in tempo reale al dispacciamento sia in batch a manutenzione e trading.

Il documento argomenta che la risposta corretta non è single-cloud, né tantomeno una replica completa multi-cloud, ma una architettura ibrida che mantiene on-prem il perimetro a maggior sensibilità e classifica i workload restanti su tre cloud pubblici secondo un criterio best-of-breed: AWS come spina dorsale ML, Azure per integrazione enterprise e LLM regolati, GCP per analytics su grandi volumi. Open source (Docker, Kubernetes, MLflow, Hugging Face) è la lingua franca che tiene insieme i tre ambienti pubblici con il perimetro privato, mitigando il lock-in senza costruire in casa un layer di astrazione proprietario.

La proiezione concettuale a 5 anni indica un risparmio cumulato intorno al 20% rispetto a una baseline on-prem only, principalmente per la sostituzione del refresh hardware periodico con consumo elastico cloud sui picchi di training. Il taglio dei costi, però, è il beneficio minore: pesano di più la flessibilità di provare nuovi modelli senza acquistare GPU e l'allineamento con i requisiti regolatori in evoluzione (NIS2 entrata in vigore nel 2024, EU AI Act, ISO 27019 per il settore energia). La roadmap raccomandata è a tre wave su 36 mesi, con gate decisionali a M9, M21 e M36 e milestone misurabili sui tre casi d'uso.

RACCOMANDAZIONE

Adottare un'architettura ibrida multi-cloud guidata da workload (non da provider). Single-cloud sui workload dove il data gravity lo impone, OSS on-prem dove la sensibilità del dato e la latenza lo richiedono. Evitare il full multi-cloud replicato: il costo operativo non è giustificato dai benefici per un operatore di questa scala.

Le sezioni successive sviluppano la motivazione di ciascuna scelta rispetto alle alternative considerate, presentano l'analisi comparativa sui criteri richiesti dalla consegna, descrivono la strategia architetturale, l'impatto economico e organizzativo, gli aspetti di sicurezza e compliance, la roadmap a wave, i KPI di successo e le raccomandazioni di chiusura.

1. Contesto e caso d'uso Energogrid

1.1 Profilo dell'azienda

Energogrid S.p.A. opera lungo l'intera catena del valore elettrico: produzione (centrali tradizionali termoelettriche e parchi di rinnovabili distribuiti), stoccaggio, trasporto e distribuzione su rete di media e bassa tensione. Lo scenario operativo è quello tipico di un'utility europea contemporanea: una quota crescente di generazione intermittente, una clientela che diventa anche produttore (prosumer), una pressione regolatoria in aumento sull'affidabilità del servizio e una rete di asset fisici eterogenea per età, tecnologia e fornitore.

Il punto di partenza tecnologico include sistemi SCADA tradizionali per il controllo della rete, una infrastruttura di telemetria IoT con copertura non uniforme (smart meter di nuova generazione affiancati a contatori legacy), data warehouse aziendali su tecnologia on-prem e una recente sperimentazione cloud su AWS per carichi non critici. Il bagaglio AI esistente è limitato a modelli statistici di forecasting di vecchia generazione gestiti in modalità poco industrializzata.

1.2 Tre scenari predittivi

La consegna individua tre casi d'uso AI con priorità alta per Energogrid. Sono trattati come un unico programma piuttosto che come tre progetti scollegati, perché condividono ingestione, feature store, governance e una larga parte dei modelli infrastrutturali.

Caso d'uso	Output operativo	Orizzonte	Frequenza
Forecasting domanda energetica	Curva di carico per nodo di rete	T+1h a T+72h	ogni 15 min
Manutenzione predittiva asset	Probabilità di guasto per inverter/trasformatore	T+24h a T+30g	ogni 1h
Ottimizzazione bilanciamento e storage	Set point di dispacciamento e cariche batteria	T+15min a T+24h	ogni 15 min

Forecasting e ottimizzazione di bilanciamento si avvalgono delle stesse features (consumi storici, meteo, prezzo zonale, stato asset); la manutenzione predittiva attinge invece dalla telemetria di basso livello degli inverter e dei trasformatori (temperature, vibrazioni, profilo di carico). Trattarli come uno stesso programma significa riusare la pipeline di ingestione e il feature store, e ridurre il costo marginale di portare in produzione il secondo e il terzo modello rispetto al primo.

1.3 Requisiti funzionali

I requisiti funzionali sono espressi al livello di programma e non come specifica di singolo modello, coerentemente con il perimetro strategico della consegna.

ID	Requisito funzionale
F1	Ingestione continua di telemetria asset da SCADA, gateway IoT industriali e smart meter, con bufferizzazione locale a tolleranza di interruzioni di rete fino a 24 ore.
F2	Pipeline di feature engineering condivisa fra i tre casi d'uso, con feature store come unica fonte di verità sia in training sia in serving.

F3	Catalogo modelli versionato con stage di promozione (development, staging, production, archived) e tracciatura completa delle metriche di valutazione.
F4	Endpoint di inferenza online per dispacciamento e ottimizzazione bilanciamento, con latenza p95 sotto 500 ms a partire dalla richiesta interna.
F5	Batch scoring giornaliero per manutenzione predittiva, con output disponibili al sistema asset management entro le 06:00 locali.
F6	Inferenza locale a bordo substation per anomaly detection a bassa latenza (target sotto 50 ms) sui parametri elettrici.
F7	Monitoraggio di drift sulla distribuzione delle feature di ingresso e sulle metriche di qualità dei modelli, con trigger automatici di retraining.
F8	Cruscotti decisionali per dispatcher e responsabili manutenzione, con accesso amministrato tramite il sistema di identità aziendale.
F9	Esportazione audit-ready di evidenze su data lineage, decisioni del modello e accessi, in formato adatto a ispezione regolatoria.

1.4 Requisiti non funzionali

I requisiti non funzionali sono i vincoli che pesano sulle scelte architetturali più di qualunque preferenza tecnologica. In un operatore di rete elettrica la priorità non è la novità del modello, è che il sistema operi 24 ore su 24 e non sia un vettore di compromissione dell'infrastruttura critica.

ID	Categoria	Requisito non funzionale
NF1	Disponibilità	RTO sotto 4 ore e RPO sotto 1 ora per le pipeline che alimentano dispatch e manutenzione.
NF2	Latenza	p95 sotto 500 ms per inferenza online, p95 sotto 50 ms per anomaly detection a substation.
NF3	Sovranità del dato	Telemetria asset e dati operativi devono risiedere in territorio italiano o EU; nessuna esportazione verso jurisdiction non adeguate ai sensi del GDPR.
NF4	Sicurezza	Conformità a NIS2 per operatori essenziali, ISO 27001/27019, IEC 62443 per la parte OT, separazione netta IT-OT a livello di rete e di identità.
NF5	Interoperabilità	Integrazione con SCADA esistenti via protocolli industriali (IEC 60870-5-104, OPC UA) senza riprogettazione degli stessi.
NF6	Portabilità	Modelli e pipeline devono poter migrare fra cloud provider con un effort di settimane, non di mesi; il vendor lock-in è inaccettabile come default architetturale.
NF7	Auditabilità	Tracciatura completa di chi ha addestrato cosa con quali dati, conservata per almeno 5 anni in conformità ai requisiti di audit interno e regolatorio.
NF8	Sostenibilità operativa	Il team interno cresce in modo graduale; la piattaforma deve essere operabile da un nucleo iniziale di 6-10 persone, non da un'organizzazione di 50.
NF9	Costo	TCO a 5 anni inferiore al 90% della baseline on-prem only; cost shape prevedibile e budgetabile per ciclo finanziario annuale.

PUNTO CRITICO

I requisiti NF2, NF3 e NF4 escludono un'architettura puramente cloud per la parte vicina agli asset fisici. NF6 e NF9 escludono una soluzione single-vendor PaaS spinta. L'intersezione dei

due vincoli porta in modo naturale a un disegno ibrido: questa non è una preferenza estetica, è l'unica scelta che soddisfa i requisiti minimi senza eccezioni esplicite.

2. Catalogo dei servizi considerati

Il catalogo include le piattaforme PaaS dei tre principali hyperscaler e il sottoinsieme open source rilevante per il caso Energogrid. La descrizione si mantiene di proposito a livello alto: il documento non valuta specifiche tecniche di servizio, ma il contributo di ciascun cluster alla strategia. La selezione all'interno di ciascun PaaS si limita ai servizi pertinenti al ciclo di vita ML, all'ingestione di telemetria industriale e alla data foundation.

2.1 PaaS AWS

AWS è il provider con il catalogo più ampio e con la maturità operativa più lunga. Per il programma Energogrid è candidato a ruolo di spina dorsale ML: SageMaker copre l'intera filiera di training, registry, deployment e drift monitoring, mentre IoT Core fornisce un canale di ingestione MQTT gestito con device registry e shadow state per la parte di gateway industriali. La scelta non implica esclusività: i workload sensibili restano on-prem e altri cloud entrano in scena dove portano vantaggi specifici.

Servizio AWS	Ruolo nella piattaforma
Amazon S3	Data lake unico per dataset di training, modelli, log e artefatti, con bucket dedicati per perimetro di classificazione.
Amazon SageMaker	Piattaforma end-to-end per training, hyperparameter tuning, model registry, endpoint REST e Model Monitor per drift detection.
Amazon Aurora	Feature store transazionale e archivio delle previsioni con consistenza ACID.
Amazon DynamoDB	Lookup a singola chiave a bassa latenza per cache di feature online e stato utente delle dashboard operative.
AWS IoT Core	Ingestione MQTT da gateway industriali, device shadow, regole di routing verso Kinesis o Lambda.
Amazon CloudWatch + EventBridge	Osservabilità di pipeline e endpoint, automazione dei trigger di retraining basati su soglie di drift.
AWS KMS + Secrets Manager	Gestione chiavi cifratura e segreti, integrabile con HSM esterno per scenari ad alta sensibilità.

2.2 PaaS Microsoft Azure

Azure ha il vantaggio strutturale dell'integrazione con la filiera Microsoft (Active Directory, Office 365, Dynamics) e il portafoglio di certificazioni più ampio per i settori regolati. Per Energogrid il ruolo naturale è duplice: ospitare i workload che si appoggiano all'identità aziendale e ai canali enterprise (reportistica per management, integrazione con strumenti di ticketing), e fornire l'accesso a modelli generativi (Azure OpenAI) sotto contratto con garanzie di non-training sui dati e data residency in regione EU.

Servizio Azure	Ruolo nella piattaforma
Azure Blob Storage	Storage oggetti per dataset di training secondari e archiviazione storica.
Azure Machine Learning	Piattaforma di training, AutoML, MLOps, endpoint gestiti per i modelli che si integrano con i sistemi Microsoft di reportistica.

Azure OpenAI Service	Accesso ai modelli GPT-4o / o-series in regione EU con garanzie contrattuali enterprise, per assistenza documentale e generazione di report.
Azure AI Foundry	Hub per la sperimentazione di agenti e LLM customizzati, isolato dal perimetro produttivo.
Azure Cosmos DB	Storico delle conversazioni operatore-assistente e cache geograficamente distribuita.
Azure IoT Hub	Canale alternativo o ridondato di ingestione per gateway che vivono nell'ecosistema Microsoft.
Azure Active Directory / Entra ID	Identità unificata, single sign-on, accesso condizionale e MFA per gli operatori.

2.3 PaaS Google Cloud

GCP si distingue per la filosofia data-first: BigQuery è il motore di analytics serverless di riferimento sul mercato e BigQuery ML porta il training dentro il warehouse, con modelli addestrati direttamente sui dati e senza esportazioni. Vertex AI fornisce il completamento naturale verso il training custom e la gestione del lifecycle. Per Energogrid GCP entra in scena nella parte analitica del programma: consolidamento storico dei consumi, segmentazioni di lungo periodo, analisi pattern di rete che richiedono scansioni su anni di telemetria.

Servizio GCP	Ruolo nella piattaforma
Google Cloud Storage	Storage oggetti per snapshot del data warehouse e backup.
BigQuery	Data warehouse analitico per consumi storici, mercato e dataset di forecasting di lungo periodo.
BigQuery ML	Training di modelli tabellari (forecasting baseline, segmentazione clienti) direttamente in SQL.
Vertex AI	Piattaforma di training custom, model registry, endpoint, Feature Store, monitoring di drift; alternativa o complemento a SageMaker.
Vertex AI Search	Retrieval ibrido vettoriale e keyword per casi d'uso di RAG su documentazione tecnica e normativa.
Dataflow + Pub/Sub	Streaming ETL e ingestione real-time per integrazione con feed di mercato e meteo ad alta frequenza.

2.4 Open-source e componenti on-prem

La componente open source affianca il cloud invece di sostituirlo: fa da strato comune che rende l'architettura portabile fra cloud e verso on-prem. Tre vantaggi strutturali ne giustificano la presenza in ogni layer: portabilità dei modelli e dei container, controllo del codice per audit di terze parti, riduzione del lock-in senza la complessità di un layer di astrazione proprietario.

Componente OSS / on-prem	Ruolo nella piattaforma
Docker	Standard di packaging per ogni modello, libreria e servizio della piattaforma; abilita la portabilità fra ambienti.
Kubernetes (K8s) + K3s	Orchestrazione cluster on-prem (K8s) e edge a substation (K3s lightweight), con stessa control plane semantica.
MLflow	Tracking degli esperimenti e Model Registry open source, fonte unica di verità per il lifecycle dei modelli indipendentemente dal cloud in cui il training avviene.

Hugging Face Hub	Catalogo modelli pre-addestrati (transformer per testo, time-series), riferimento per supply chain dei modelli con versioning e model card.
FastAPI	Layer di serving Python, con OpenAPI automatico per integrazione con i sistemi consumer.
Apache Kafka	Backbone di streaming dati per ingestione telemetria; standard di settore con ecosistema connector ampio.
MinIO	Object storage S3-compatible on-prem per i dataset sensibili che non lasciano il perimetro.
TimescaleDB	Time-series database PostgreSQL-compatible, idoneo per storicizzazione telemetria a media frequenza.
Prometheus + Grafana	Stack di osservabilità end-to-end di metriche infrastrutturali, applicative e di modello.
HashiCorp Vault	Gestione segreti e chiavi cifratura unificata fra cloud e on-prem, riduce il drift fra IAM dei singoli provider.

PRINCIPIO GUIDA

Ogni servizio PaaS adottato deve essere accessibile da codice interno tramite un'astrazione che non lo nomini esplicitamente fuori dal modulo di integrazione. Così la portabilità resta un'opzione operativa, non una promessa marketing.

3. Criteri di valutazione comparativa

La consegna richiede otto criteri di valutazione. Tutti sono strategici (non operativi) e sono interpretati come domande sul ruolo che ciascun cluster di soluzioni può coprire nella piattaforma Energogrid. Per ogni criterio sono indicati: la definizione operativa, i driver concreti e il metodo di confronto applicato nella [sezione 4](#).

Il metodo è qualitativo su scala 1-5, discreto per scelta. Una valutazione su scala continua avrebbe richiesto stime numeriche puntuali (per esempio euro / mese / req) che a livello concettuale sarebbero state pretese di precisione non giustificabili. La granularità 1-5 è sufficiente a discriminare i cluster e lascia esplicito il margine di errore.

Scala	Etichetta	Significato
1	debole	non soddisfa il requisito senza interventi sostanziali
2	sotto la media	soddisfa parzialmente, gap rilevanti
3	adeguato	soddisfa il requisito a livello base
4	forte	soddisfa il requisito con margine, pochi gap
5	best-in-class	riferimento di mercato sul criterio

3.1 Costo (TCO 3-5 anni)

Costo totale di possesso su orizzonte 3 e 5 anni, includendo spese ricorrenti (run-time, storage, traffico), licenze, sforzo di operations e refresh hardware dove applicabile.

Driver principali:

- spesa per inferenza (per call su PaaS, per ora-GPU su OSS);
- spesa per storage e per egress cross-cloud;

- licenze enterprise (osservabilità, security, supporto);
- ammortamento hardware e ciclo di refresh (solo on-prem);
- costo del personale di operations dedicato.

3.2 Scalabilità e resilienza

Capacità di scalare training e inference, gestire picchi di carico (per esempio in fase di tempesta che induce stress sulla rete) e garantire ridondanza geografica.

Driver principali:

- elasticità di compute e storage;
- tempo di provisioning per scenario di picco;
- modello di disaster recovery e RTO/RPO;
- supporto a multi-region con failover automatico.

3.3 Sicurezza e compliance

Insieme dei controlli di sicurezza nativi e delle certificazioni che riducono lo sforzo di compliance per il settore energia.

Driver principali:

- controlli IAM granulari e supporto per separazione IT-OT;
- cifratura at-rest e in-transit, gestione chiavi (KMS, HSM);
- isolamento multi-tenant, network segmentation, private link;
- auditability (audit log, immutabilità, conservazione);
- certificazioni (ISO 27001/27019, SOC 2, ENISA, conformità NIS2, EU AI Act).

3.4 Portabilità e rischio di vendor lock-in

Costo di migrazione e interoperabilità fra ambienti. È una variabile strategica per un operatore di rete: la durata di esercizio dei sistemi è decennale, le scelte di provider andranno riviste più di una volta.

Driver principali:

- dipendenza da API proprietarie vs standard aperti;
- formato di interscambio per modelli e dataset;
- facilità di eseguire la stessa pipeline su provider alternativo;
- presenza di clausole contrattuali sulla portabilità.

3.5 Operabilità e ciclo di vita ML

Supporto end-to-end al ciclo di vita: experiment tracking, model registry, deployment, monitoring di drift, retraining automatizzato.

Driver principali:

- experiment tracking integrato;
- model registry con stage e approvazione;
- deployment automatizzato a endpoint o batch;
- monitoring di drift di input e output;

- supporto a CI/CD/CT (continuous training).

3.6 Ecosistema e integrazione

Disponibilità di connettori e SDK verso i sistemi che la piattaforma deve consumare o servire: SCADA, IoT industriali, ERP, asset management, CRM.

Driver principali:

- connettori per protocolli industriali (OPC UA, IEC 60870-5-104, Modbus);
- SDK e bridge verso ERP (SAP, Oracle) e CRM;
- integrazione DevOps con repository di codice e CI;
- ricchezza dell'ecosistema marketplace e partner.

3.7 Supporto e comunità

Disponibilità di supporto commerciale (SLA, account management, escalation path) e robustezza della comunità open source di riferimento.

Driver principali:

- presenza locale (Italia / EU) del supporto vendor;
- tempo di risposta su severity 1;
- dimensione e attività della comunità OSS per i componenti adottati.

3.8 Time-to-market e agilità

Tempo per portare in produzione una nuova capacità AI dalla decisione di business al primo rollout pilota.

Driver principali:

- tempo di provisioning di un nuovo workload;
- presenza di template e accelerator pronti all'uso;
- snellezza del processo di approvazione interno indotto dalla soluzione.

4. Analisi comparativa

4.1 Mappa di sintesi criteri x cluster

La figura 4.1 sintetizza il punteggio assegnato a ciascun cluster di soluzioni sui criteri della [sezione 3](#). La lettura raccomandata è per colonna: il profilo di ciascun cluster emerge dal pattern di forze e debolezze, non dal punteggio aggregato. Aggregare in una media unica sarebbe ingannevole, perché i criteri non hanno tutti lo stesso peso per Energogrid (sicurezza, portabilità e operabilità pesano più di time-to-market in un settore regolato).

Mapa di valutazione: criteri x cluster di soluzione

Scala qualitativa 1-5 (1 = debole, 5 = best-in-class)

	AWS PaaS	Azure PaaS	GCP PaaS	OSS on-prem	Hybrid mix
Costo (TCO 3-5y)	3	3	3	5	4
Scalabilità & resilienza	5	5	5	3	4
Sicurezza & compliance	4	5	4	4	5
Portabilità & lock-in	2	2	3	5	4
Lifecycle ML	5	5	5	3	4
Ecosistema & integrazione	5	5	4	3	5
Supporto & comunità	5	5	4	4	4
Time-to-market	5	5	5	2	4

1 debole
 2 sotto media
 3 adeguato
 4 forte
 5 best-in-class

Figura 4.1 - Mapa qualitativa criteri x cluster di soluzioni. Scala 1-5, lettura per colonna.

4.2 Pro e contro per cluster

I cinque cluster sono valutati di seguito, ciascuno con il profilo che emerge dalla heatmap, le forze sostanziali per il caso Energogrid e i limiti che devono essere mitigati per renderli utilizzabili in produzione.

4.2.1 AWS PaaS

Profilo: best-in-class su scalabilità, operabilità ML, ecosistema e supporto; forte su sicurezza; adeguato su costi; sotto la media su portabilità.

AWS ha la piattaforma ML più matura del mercato: SageMaker copre con un solo set di API training, registry, deployment e monitoring, IoT Core regge l'ingestione MQTT a scala industriale, e la maturità si traduce in documentazione, runbook e partner presenti in Italia. Il punto debole è la portabilità: uscire da SageMaker richiede di riscrivere la filiera di training e serving. La compliance generale è solida (ISO 27001, EU Cloud CoC), ma quella specifica per l'energia (ISO 27019, IEC 62443) va verificata puntualmente, non è garantita come pacchetto unico.

4.2.2 Azure PaaS

Profilo: best-in-class su sicurezza e compliance, scalabilità, operabilità ML, ecosistema e supporto; adeguato su costi; sotto la media su portabilità.

Azure ha il portafoglio di certificazioni più ampio del settore (GDPR, ISO 27001/27017/27018, FedRAMP, ENISA Cloud Security e ISO/IEC 27019 esplicito per l'energia) e l'integrazione nativa con Active Directory e la filiera Microsoft riduce attrito su identità aziendale e

reportistica per il management. Azure OpenAI Service è la via più diretta verso modelli generativi sotto vincoli enterprise. Il limite è lo stesso di AWS sulla portabilità (SDK e formati non standard de facto); l'integrazione con i protocolli industriali (OPC UA, IEC 104) non è first-class e richiede componenti aggiuntivi o partner certificati.

4.2.3 GCP PaaS

Profilo: best-in-class su scalabilità, operabilità ML e time-to-market; forte su sicurezza ed ecosistema; adeguato su portabilità e costi.

GCP è il provider migliore quando il problema è dominato dai dati. BigQuery non ha equivalenti immediati: petabyte di telemetria interrogabili in SQL senza gestire cluster, e BigQuery ML addestra modelli tabellari (forecasting baseline, segmentazione di rete) direttamente sul warehouse, in minuti e senza esportazioni; Vertex AI chiude verso i modelli custom. Le debolezze sono la presenza enterprise in Italia meno diffusa rispetto ad AWS e Azure (supporto in inglese, meno partner locali) e certificazioni per l'energia presenti ma meno consolidate nei dossier regolatori.

4.2.4 OSS on-prem

Profilo: best-in-class su costi e portabilità; forte su sicurezza e supporto; adeguato su scalabilità, operabilità ed ecosistema; sotto la media su time-to-market.

L'OSS on-prem è la risposta corretta dove il dato non può uscire dal perimetro e la latenza deve restare sotto il centinaio di millisecondi. Lo stack di riferimento (Kubernetes + MLflow + FastAPI + Prometheus + Grafana) è standard nel settore, con comunità attive e supporto enterprise (Red Hat, SUSE, Canonical) per chi vuole garanzie contrattuali; ammortizzato l'hardware, il costo unitario di inferenza è il più basso fra le opzioni per volumi prevedibili. Il costo nascosto è il time-to-market: allestire un cluster ML on-prem maturo richiede mesi (hardware, rete, policy IAM) contro i giorni del cloud, e la scalabilità elastica resta limitata dal parco hardware, lenta sui picchi imprevisti.

4.2.5 Hybrid mix

Profilo: best-in-class su sicurezza, compliance ed ecosistema; forte sugli altri criteri; adeguato sui costi.

L'hybrid mix non è un cluster a sé stante: è la combinazione strategica dei precedenti. Il suo profilo nella heatmap è figlio della scomposizione dei workload: il forecasting su volumi prevedibili va su cloud PaaS, la manutenzione predittiva sensibile resta on-prem, le componenti generative vanno su Azure OpenAI per garanzie contrattuali, le aggregazioni su BigQuery dove i dati storici lo giustificano. Ogni cluster porta la sua forza, mentre il prezzo da pagare è la complessità operativa: il rischio operativo dell'hybrid è reale e gestirlo consuma una parte sostanziale del beneficio ([sezione 6](#)).

LETTURA SINTETICA

Nessun cluster vince da solo su tutti i criteri rilevanti per Energogrid. AWS e Azure perdono sulla portabilità, GCP perde sulla presenza locale, OSS on-prem perde sul time-to-market, l'hybrid perde sulla complessità operativa. La strategia raccomandata è un hybrid disciplinato, costruito attorno al principio di assegnare ogni workload al cluster dove la sua intersezione di vincoli rende l'opzione dominante.

5. Strategia architetturale concettuale

5.1 Principi guida

Cinque principi guidano ogni scelta architetturale a valle. Funzionano come criteri di decisione binari, applicati in modo deterministico quando emerge un'ambiguità sulla collocazione di un componente.


Principio	Applicazione operativa
Edge-to-cloud per default	I dati nascono all'edge, vengono aggregati on-prem e replicati selettivamente in cloud. Il percorso inverso è eccezione, non regola.
Data sovereignty inderogabile	Telemetria asset e dati operativi restano in jurisdiction EU. Qualsiasi servizio PaaS che non garantisca residency esplicita è escluso.
Portabilità by design	Ogni servizio PaaS è incapsulato in un'astrazione interna che ne nasconde l'origine. Sostituirlo richiede settimane, non mesi.
Open source come collante	Le interfacce fra cluster (registry modelli, observability, IaC, identità) usano standard open source. Le scelte proprietarie sono ammesse solo dentro i confini di un singolo cluster.
Operability prima dell'efficienza	Una architettura che il team non sa operare è un debito tecnico, non un asset. Le decisioni privilegiano l'osservabilità e la semplicità operativa anche a costo di una marginale perdita di efficienza.

5.2 Componenti logici della piattaforma

La piattaforma è strutturata in quattro layer logici indipendenti dal provider che li ospita. La separazione è intenzionale: ogni layer è realizzato dal cluster di soluzioni che meglio lo serve, e cambia provider in modo controllato senza riprogettazione del resto.

Architettura ibrida multi-cloud

Quattro layer: Edge - Private on-prem - Public multi-cloud - Consumers




Flusso unidirezionale top-down. Cross-cloud assente per design: ogni use case è assegnato a un solo cloud.

Figura 5.1 - Architettura concettuale ibrida multi-cloud. Quattro layer (edge, private, public, consumers) collegati da flussi verticali unidirezionali top-down; cross-cloud assente per design.

Il flusso del dato attraversa i quattro layer in modo asimmetrico: la maggior parte del traffico sale dagli asset fisici verso la piattaforma analitica (telemetria, eventi, stato operativo), mentre solo decisioni e modelli aggiornati scendono in senso opposto. La figura 5.2 esplicita questa direzionalità e la classifica delle categorie di dato che percorrono la pipeline, dato che la sensibilità di ciascuna determina dove può essere processata.

Flusso dati edge-to-cloud

Dalla telemetria di campo alla decisione operativa



Loop di retraining attivato dal drift monitor (Sezione 7).

Figura 5.2 - Flusso dati edge-to-cloud. Sei stadi sequenziali dalla sorgente al consumer; il loop di retraining su drift è descritto nella [sezione 7](#).

Layer	Cosa fa	Dove vive di default
Edge & impianti	Acquisizione telemetria, controllo locale, inferenza a bassa latenza su anomaly detection	On-prem (centrali, parchi, substation), edge runtime K3s
Private cloud	Data hub on-prem, OSS ML platform per modelli sensibili, vault per segreti, identità unificata	Data center primario Energogrid
Public cloud (multi-cloud)	Training elastico, batch scoring su grandi volumi, modelli generativi, analytics warehouse-scale	Landing zone AWS, Azure, GCP secondo workload
Consumer	Cruscotti dispatcher, asset management, trading, reporting regolatorio	Sistemi aziendali esistenti, integrati via API

5.3 Pattern di distribuzione dei workload

Il framework decisionale che assegna ciascun workload al cluster corretto è volutamente semplice. Due sole domande, applicate in ordine, conducono a una raccomandazione iniziale; i guardrail trasversali assicurano che la scelta non comprometta i principi della [sezione 5.1](#).

Decision tree: scelta del deployment per use case

Quattro domande, cinque esiti possibili




Figura 5.3 - Framework decisionale per l'assegnazione di un workload AI: quattro domande, cinque esiti (hybrid burst, OSS on-prem, PaaS pieno, PaaS curato, IaaS+OSS).

L'applicazione del framework ai tre casi d'uso Energogrid produce una distribuzione che evita la trappola del single-cloud e quella opposta del full multi-cloud replicato.


Caso d'uso	Componente principale	Cluster di destinazione	Motivazione
Forecasting domanda	Training	GCP (BigQuery + Vertex AI)	I dati di consumo e di mercato vivono nel warehouse, il training tabellare è nativo, latenza accettabile
Forecasting domanda	Serving online	AWS SageMaker endpoint	Coerenza con resto del programma ML, autoscaling, esposizione via API gateway esistente
Manutenzione predittiva	Training	On-prem OSS	Dati di telemetria sensibili, vincolo di sovranità, volumi gestibili da GPU pool interno
Manutenzione predittiva	Serving	On-prem (batch) + edge (anomaly real-time)	Batch scoring giornaliero notturno; inferenza edge a substation per anomaly su parametri elettrici
Ottimizzazione bilanciamento	Training	On-prem OSS	Logica core dell'operatore, vincolo di sovranità totale, no esposizione esterna
Ottimizzazione bilanciamento	Serving online	On-prem OSS	Latenza p95 sotto 500 ms verso dispatcher, integrazione diretta con SCADA
Reportistica e documentazione	LLM enterprise	Azure OpenAI Service (regione EU)	Garanzie contrattuali enterprise, integrazione con Office 365 e Teams

Tradotta in termini di lifecycle, l'assegnazione produce due lane di esecuzione che condividono lo stesso model registry (MLflow) come fonte unica di verità. La private lane

esegue training su dati sensibili e mantiene endpoint a bassa latenza verso il dispatch; la public lane esegue training non sensibile su GPU spot e mantiene endpoint per workload elastici. La figura 5.4 esplicita come modelli e drift signal attraversano le lane senza che i dati sensibili lascino mai il perimetro privato.

Lifecycle ML ibrido

Lane private e public si incontrano nel model registry



Un solo registry per entrambe le lane. Drift loop riportato in Sezione 7.

Figura 5.4 - Lifecycle ML ibrido. Private e public lane condividono un unico model registry; la promozione a produzione passa per approvazione esplicita (promote-on-approval).

5.4 Modello di responsabilità multi-cloud

L'introduzione di tre cloud pubblici e dell'OSS on-prem moltiplica i punti di responsabilità. Una matrice esplicita di chi-fa-cosa è una preconditione operativa, non una formalità. La tabella sintetizza la responsabilità di alto livello sui domini principali. Il dettaglio operativo è rimandato ai runbook di ciascun workstream.

Dominio	Provider PaaS	Energogrid IT	Energogrid OT	Energogrid ML
Hardware fisico	Cloud	Data center	OT plant	n/a
Sistema operativo	Cloud (PaaS)	On-prem	On-prem OT	n/a
Container runtime	Cloud	On-prem	Edge	n/a
Dati grezzi	n/a	Pipeline	Sorgente	n/a
Feature engineering	n/a	n/a	n/a	Owner
Modelli e training	n/a	n/a	n/a	Owner
Deployment endpoint	Runtime	Network	n/a	Codice
Drift monitoring	Tooling	n/a	n/a	Owner
Identità e accessi	IAM service	Owner	OT-IAM	Consumer
Audit log	Servizio	Aggregazione	OT events	Eventi ML
Compliance regolatoria	Certificazioni	Coordina	OT compliance	Modelli e dati

IMPLICAZIONE

La matrice mette in chiaro un punto facile da sottovalutare: ogni dominio ha un owner unico ma tre o quattro contributori. La governance va trattata come condizione di partenza: è ciò che impedisce alla responsabilità di evaporare nei punti di contatto fra cluster ([sezione 7](#)).

6. Impatto su processi e costi

6.1 Impatto organizzativo

L'architettura ibrida cambia il profilo di capacità del team. Un'organizzazione progettata per gestire infrastruttura esclusivamente on-prem deve evolvere in tre dimensioni: cloud engineering (FinOps, IaC, networking cross-cloud), MLOps (experiment management, model registry, drift), governance tecnica (IAM unificato, audit cross-cloud, compliance evidenze).

Capacità	Stato iniziale	Target a regime	Modalità di build
Cloud engineering / FinOps	Limitato, sperimentale su AWS	Team dedicato 4-6 FTE multi-cloud certificati	Hiring esterno + percorso di certificazione interno
MLOps / data engineering	Modelli statistici legacy, no MLOps	Squadra 6-8 FTE su MLflow, feature store, monitoring drift	Hiring senior + formazione interna su giuniori
Cybersecurity OT	Solido sul perimetro tradizionale	Esteso al perimetro cloud, IEC 62443 + zero trust	Upskilling team esistente + consulenza specialistica
Governance e compliance	Funzione regolatoria classica	Funzione tecnica con evidenze automatizzate audit-ready	Estensione del team risk con un product manager dedicato
Solution architecture	Pratica concentrata su singoli sistemi	Architetti cross-cloud con visione di programma	Promozione interna + uno o due senior dall'esterno

Il piano di transizione è incrementale: la wave 1 della roadmap ([sezione 8](#)) è dimensionata per essere sostenibile dal team di partenza, con onboarding di rinforzi durante la wave 2 e stabilizzazione del modello operativo in wave 3. Forzare la trasformazione organizzativa prima dell'infrastruttura genera frustrazione e turnover; muoversi nella sequenza opposta fa imparare sul prodotto reale, non su slide.

6.2 TCO concettuale a 5 anni

La proiezione TCO resta a livello concettuale. Non vengono stimati euro puntuali per voce: l'incertezza intrinseca su volumi, prezzi unitari cloud e ciclo di refresh hardware renderebbe una stima numerica dettagliata fuorviante. L'obiettivo è confrontare la forma del costo on-prem only contro l'hybrid multi-cloud sull'orizzonte 5 anni e identificare i driver principali.


Proiezione TCO a 5 anni (concettuale): on-prem only vs hybrid multi-cloud

Figura 6.1 - Proiezione concettuale del TCO a 5 anni. Le unità sono proxy normalizzati: la grandezza informativa è il rapporto fra le due curve, non il valore assoluto.

Tre osservazioni emergono dalla figura:

- Anno 1: lo scenario hybrid è già più economico dello scenario on-prem only, perché evita il refresh hardware massiccio per GPU di training. Il differenziale (~30%) è il maggior beneficio del periodo di startup.
- Anni 2-4: la curva on-prem ha un creep operativo lento ma costante (ricambio licenze, manutenzione, consumo energetico); la curva hybrid è praticamente piatta, perché il costo variabile cloud assorbe l'incremento di volume mentre la base on-prem resta dimensionata sul perimetro sensibile.
- Anno 5: il differenziale cumulato si attesta intorno al 20%. Non è il numero da raccontare al CFO come unica metrica: il valore vero è la differente flessibilità. L'hybrid permette di assorbire un raddoppio del volume di forecasting senza acquisti CAPEX; l'on-prem only richiederebbe un altro refresh.

L'hybrid porta driver di costo nascosti noti dalla letteratura cloud: egress cross-cloud, tooling di osservabilità unificato, operations multi-cloud, perdita di volume discount e GPU idle in training. Sono coperti esplicitamente nella mappa dei rischi ([sezione 8.3](#)), che ne riporta mitigazione e owner.

7. Sicurezza, compliance e data governance

Per un operatore di rete energetica la sicurezza non è un modulo aggiuntivo: è il contesto in cui ogni altra scelta vive. La sezione è organizzata per scendere progressivamente dal quadro normativo applicabile, ai controlli per dominio, alla data governance, fino alla checklist di alto livello che Energogrid può usare come baseline di valutazione interna.

7.1 Quadro normativo applicabile

Le normative rilevanti per Energogrid che impattano l'architettura della piattaforma AI sono cinque, ciascuna con implicazioni diverse sul disegno e sui controlli da prevedere.

Norma	Ambito	Implicazione architetturale
GDPR (Reg. UE 2016/679)	Dati personali di clienti e dipendenti	Data residency EU, accesso controllato, diritto alla cancellazione, registro trattamenti
NIS2 (Dir. UE 2022/2555)	Operatori essenziali, sicurezza cyber e resilienza	Notifica incidenti entro 24h, gestione vulnerabilità, SBOM, piano DR testato
EU AI Act (Reg. UE 2024/1689)	Sistemi AI ad alto rischio, gestione e trasparenza	Sistemi di gestione del rischio, conservazione log, supervisione umana sui sistemi critici
ISO/IEC 27001 + 27019	ISMS generico + specifico settore energia	Gestione asset, controlli su accesso, fornitori, business continuity
IEC 62443	Cybersecurity per industrial automation	Segmentazione zone/conduit, security level per zona, hardening componenti OT

Energogrid rientra come operatore essenziale sotto NIS2 (settore energia, sottosettore elettricità); l'attivazione AI più sensibile (ottimizzazione dispacciamento) ricade nel perimetro AI Act come sistema potenzialmente ad alto rischio (gestione di infrastruttura critica). Questi due punti vincolano l'architettura più di GDPR e ISO, che sono prerequisiti già coperti dai processi aziendali esistenti.

7.2 Controlli per dominio

I controlli sono organizzati per dominio funzionale: identità, dato, modello, rete, edge, audit. La figura 7.1 sintetizza la mappa, evidenziando i principi al centro (least privilege, zero trust, data sovereignty) e l'inquadramento normativo agli angoli.

Mappa dei domini di governance multi-cloud

Principi (header) -> domini (corpo) -> norme applicabili (footer)




Figura 7.1 - Mappa dei domini di governance multi-cloud. Fascia dei principi in alto, sei domini nella griglia centrale, norme applicabili nella fascia inferiore.

Dominio	Controlli chiave
Identità e accessi	IAM federato Entra ID + provider cloud, MFA obbligatorio, role-based access con review trimestrale, separazione IT vs OT a livello di identità
Dato	Classificazione esplicita (pubblico, interno, confidenziale, riservato OT), cifratura at-rest e in-transit con chiavi gestite via HashiCorp Vault, data lineage end-to-end
Modello	Model registry centralizzato (MLflow), approvazione esplicita per promozione a produzione, model card per ogni versione, evaluator di bias e fairness dove applicabile
Rete	Segmentazione zone IEC 62443, private link verso ogni cloud, no esposizione pubblica di endpoint operativi, ispezione del traffico cross-cloud
Edge	Device identity con certificati hardware, OTA firmati e verificati, hardening del runtime K3s, monitoring di tampering fisico
Audit	Log centralizzato (siem) con immutabilità WORM, retention 5+ anni, alerting su pattern anomali, evidenze esportabili in formato audit-ready

7.3 Data governance e lineage

La data governance è la disciplina che evita che la piattaforma diventi un buco nero in cui si vede entrare dato e uscire previsioni, senza tracciabilità di cosa è successo nel mezzo. Per Energogrid quattro pratiche sono non negoziabili.

1. Catalogo dati centrale con classificazione esplicita e owner documentato per ciascun dataset, sia all'origine sia nelle trasformazioni intermedie.
2. Data lineage automatico, tracciato dalle pipeline di ingestione fino alle feature usate dai modelli; ogni previsione è ricostruibile a ritroso fino ai dati grezzi che l'hanno prodotta.
3. Feature store come unica fonte di verità: nessuna feature viene calcolata in app code; ogni feature ha definizione, owner, criteri di freshness e signature.
4. Conservazione retention-aware: ogni dataset ha politica di retention esplicita (tipicamente 5 anni per i dati operativi che entrano in modelli ad uso regolato, durata di vita asset per la telemetria critica), automatizzata via lifecycle policy.

7.4 Checklist di alto livello

La checklist sintetizza i requisiti minimi di compliance e sicurezza che Energogrid deve garantire prima del passaggio in produzione di ogni workload AI. Non sostituisce gli audit regolatori; serve come gate operativo interno e come traccia per le evidenze.

Area	Requisito minimo	Riferimento
Residency	Dato di telemetria e PII in regione EU, contratto sub-processor verificato	GDPR, NIS2
Identità	MFA + accesso condizionale per ogni utente, separazione IT-OT	ISO 27001, IEC 62443
Cifratura	At-rest AES-256 con chiavi in Vault, in-transit TLS 1.3, rotazione chiavi automatica	ISO 27001, NIS2
Audit	Log immutabili 5+ anni, evidenza accessi privilegiati, alert su anomalie	NIS2, EU AI Act
Modello	Model card, valutazione bias dove applicabile, approvazione esplicita per prod	EU AI Act

DR	Piano DR documentato, RTO < 4h, RPO < 1h, test annuale	NIS2, ISO 27001
Vulnerability	Patch SLA chiaro, SBOM per ogni componente, scanning automatico CI/CD	NIS2
Incident	Notifica regolatore entro 24h, runbook documentati, exercise annuale	NIS2
Fornitori	Due diligence sub-processor, valutazione sicurezza periodica, exit strategy	ISO 27001, NIS2
Supervisione	Human-in-the-loop per decisioni di dispacciamento, override sempre disponibile	EU AI Act

NOTA

Le voci della checklist sono di alto livello: ciascuna si traduce in decine di controlli specifici nei framework di riferimento. L'obiettivo qui non è fare la mappatura dettagliata, ma garantire che ogni area sia presidiata fin dalla fase di disegno e non lasciata come debito da risolvere dopo il go-live.

8. Piano di migrazione e roadmap

La roadmap copre 36 mesi ed è organizzata in tre wave sequenziali ma sovrapposte: ogni wave entra in esecuzione mentre la precedente passa a stabilizzazione. La scelta di un orizzonte triennale è deliberata: la consegna privilegia profondità strategica e visibilità regolatoria piuttosto che il rilascio rapido di una capacità isolata. Una roadmap a 12 mesi sarebbe stata adeguata per un MVP, ma non per un programma che ridisegna il modello operativo AI di un operatore essenziale.

8.1 Strategia incrementale a tre wave




Figura 8.1 - Roadmap di migrazione a tre wave su 36 mesi, con tre workstream paralleli (infra & governance, ML platform & lifecycle, use case delivery), sei milestone su timeline e tre gate strategici.

Wave	Mesi	Obiettivo strategico	Output principali
Wave 1 · Foundations	M0-M9	Costruire la fondazione: landing zone multi-cloud, governance baseline, data hub on-prem, primo pilota in produzione	Landing zone su 1 cloud + on-prem, IAM federato, OSS ML platform v1, pilota forecasting su nodo rappresentativo
Wave 2 · Hybrid lifecycle	M6-M21	Industrializzare il ciclo di vita ML: feature store, registry, drift monitoring, automazione retraining	MLflow operativo, feature store condiviso, pred. maintenance in produzione, secondo cloud onboarded
Wave 3 · Scale & optimisation	M18-M36	Scalare il programma, ottimizzare costo e affidabilità, estendere edge inference	Dispatch optimisation in prod, edge runtime a substation pilota, multi-region per DR, ottimizzazione TCO

La sovrapposizione fra wave è voluta: la wave successiva ha bisogno di alcune fondamenta dalla precedente, e sospendere lo sviluppo per attendere la chiusura formale costerebbe calendario senza ridurre il rischio. La gestione di questa sovrapposizione è la responsabilità del program manager del capstone, supportata dai gate strategici dove le decisioni di proseguire o riallineare vengono prese formalmente.

8.2 Milestone e gate strategici

ID	Mese	Milestone	Cosa significa raggiungerla
M1	M3	Landing zone operativa	Primo cloud configurato con guardrail di sicurezza, network, IAM federato; sub-processor approvati
M2	M9	Pilota forecasting live	Modello forecasting in produzione su nodo pilota, output integrato al dispatcher, drift monitoring attivo
M3	M15	Feature store condiviso	Feature store operativo, almeno 30 feature documentate, condiviso tra forecasting e manutenzione predittiva
M4	M21	Pred. maint. in produzione	Modello manutenzione predittiva su flotta inverter completa, integrato con asset management, retraining automatico
M5	M27	Dispatch optimisation	Algoritmo di ottimizzazione bilanciamento in produzione con supervisione umana, gate AI Act soddisfatto
M6	M36	Regime operativo	Tre casi d'uso in regime, OPEX stabilizzato, KPI di programma raggiunti, modello operativo replicabile

I tre gate strategici sono punti di decisione formale, non checkpoint informativi. La decisione richiede sponsorship esplicito del comitato di programma e ha tre esiti possibili: procedere, riallineare scope o budget, fermare il programma.

Gate	Mese	Decisione	Criteri di valutazione
G1 · Go/No-Go pilot	M3	Procedere oltre la wave 1?	Landing zone sicura, primo modello in training in cloud, NO trovati sulla compliance baseline

G2 · Approval scaling	M15	Sbloccare la wave 2?	Pilota forecasting in produzione stabile da almeno 60 giorni, KPI MAPE entro target, budget M0-M15 nei limiti
G3 · Vendor review	M27	Confermare o ribilanciare il mix cloud?	Analisi TCO reale vs forecast, valutazione concentrazione spesa, opportunità di consolidamento, contratto pluriennale

8.3 Rischi principali e mitigazioni

I rischi principali sono stati posizionati su una mappa probabilità x impatto. La zona rossa (probabilità o impatto alti) raccoglie i rischi che hanno una mitigazione attiva nella wave 1 della roadmap, perché lasciarli aperti oltre il primo gate avrebbe ripercussioni a cascata.

Heatmap rischi: probabilità x impatto

Quindici rischi censiti, scala 1-5; severità = prob x impatto




Figura 8.2 - Mappa probabilità x impatto dei rischi principali. La zona rossa richiede mitigazione esplicita nella roadmap.

ID	Rischio	Mitigazione raccomandata	Owner
R1	Cross-cloud egress costs	Co-localazione regionale, batch instead of streaming dove possibile, monitoraggio dedicato	FinOps + Cloud Engineering
R2	Skill gap MLOps	Piano hiring senior in wave 1, percorso certificazione interna, partnership formazione con vendor	HR + ML Engineering
R3	Vendor lock-in PaaS	Astrazione interna obbligatoria, uso preferenziale di componenti OSS, exit strategy documentata	Solution Architecture
R4	Drift modelli non rilevato	Drift monitoring automatico da wave 1, alert su SLO, runbook di retraining	ML Engineering
R5	Incidente cyber su SCADA	Segmentazione IT-OT rigorosa, IEC 62443 baseline, exercise periodici, SOC dedicato OT	Cybersecurity OT


R6	Lentezza interop con sistemi legacy	POC di integrazione in wave 1, abstraction layer dedicato, fallback a integrazione asincrona	Solution Architecture + IT legacy
R7	Audit normativo NIS2	Evidenze automatizzate fin dalla wave 1, mock audit semestrale, relazione con autorità competente	Governance & Compliance
R8	Adozione utenti operativi insufficiente	Coinvolgimento dispatcher dalla fase di design, change management strutturato, formazione continua	Operations + Change Management
R9	Costo unbudgeted GPU cloud	Quota cloud per progetto, spot/preemptible per training non urgente, alert anomali su billing	FinOps
R10	Failover cross-region che non funziona	DR drill annuale (chaos engineering), runbook automatizzati, validazione RTO/RPO via test	Cloud Engineering + Operations

9. KPI di progetto e misurazione

I KPI sono organizzati in albero gerarchico, con il valore di business alla radice e le metriche operative misurabili come foglie. La gerarchia evita due errori frequenti: misurare solo metriche di output (precision, recall) senza collegarle al business, e raccontare risultati di business non riconducibili a metriche misurabili. Il sistema di misurazione è parte integrante della piattaforma, non una funzione di reportistica successiva.

Albero dei KPI di progetto

Valore di business -> macro KPI -> metriche operative



Le metriche operative sono misurabili settimanalmente. Il valore di business si rivede in steering trimestrale.

Figura 9.1 - Albero dei KPI di progetto. Valore di business in radice, tre KPI macro intermedi, sei metriche operative alle foglie.

9.1 KPI di business

KPI	Definizione	Target a 24 mesi	Baseline
MAPE forecasting domanda	Mean Absolute Percentage Error su forecast T+24h aggregato per macro-nodo	$\leq 4\%$	~7% (modelli statistici legacy)
MTBF asset rotanti	Mean Time Between Failures su inverter e trasformatori monitorati	+15% rispetto a baseline	Misurazione attuale da asset management
Costo bilanciamento (EUR/MWh)	Costo medio per MWh di sbilanciamento attribuibile a previsione/ottimizzazione	-8% rispetto a baseline	Costo storico ultimi 24 mesi
Riduzione downtime non pianificato	Ore di downtime non pianificato su asset monitorati, media annuale	-20% in 24 mesi	Registro incidenti operativi
Penetrazione rinnovabili gestibile	Quota di rinnovabili che la rete può assorbire senza intervento manuale di stabilizzazione	+10 punti percentuali	Misurazione attuale dispatcher

9.2 KPI tecnici e operativi (MLOps)

KPI	Definizione	Target
Time-to-deploy modello	Tempo dalla decisione di promozione alla disponibilità in produzione	≤ 2 settimane
Frequenza retraining	Cadenza media di retraining automatico per ciascun modello in produzione	settimanale o triggered da drift
Tasso di rollback	Percentuale di modelli che vengono rolled-back entro 30 giorni dal deploy	$\leq 5\%$
Drift detection latency	Tempo medio fra l'insorgenza di drift e la generazione dell'alert	≤ 24 ore
Endpoint availability	Disponibilità degli endpoint di serving online	$\geq 99.9\%$
Inferenza p95 (online)	Latenza percentile 95 dei serving endpoint online	≤ 500 ms
Inferenza p95 (edge)	Latenza percentile 95 dell'anomaly detection a substation	≤ 50 ms

9.3 KPI di governance e compliance

KPI	Definizione	Target
Gap NIS2 aperti (critici)	Numero di gap critici di compliance NIS2 non ancora chiusi	0 dopo M9, mantenuto
Audit findings (critici)	Findings di audit interno o esterno classificati critici	0 in regime
Coverage audit log	Percentuale di azioni privilegiate coperte da log centralizzato	$\geq 100\%$ (a regime)
Incidenti cyber su perimetro OT	Numero di incidenti cyber con impatto su perimetro OT	0 in 12 mesi continuativi
Time-to-notification NIS2	Tempo dall'incidente alla notifica al regolatore	≤ 24 ore

Model card coverage	Percentuale di modelli in produzione dotati di model card aggiornata	>= 100%
Bias review coverage	Percentuale di modelli applicabili (impatto su persone/decisioni operative) con review bias annuale	>= 100%

9.4 Sistema di misurazione

I KPI sono raccolti automaticamente dalla piattaforma: la reportistica manuale è bandita perché non scala e perché introduce ritardo nella reazione. Tre meccanismi coprono la raccolta.

1. Per i KPI di business: pipeline batch giornaliera che aggrega le previsioni e i risultati osservati nel data warehouse, calcola il delta e lo espone in dashboard Grafana / Power BI.
2. Per i KPI tecnici e operativi: Prometheus + MLflow estraggono metriche dai servizi e dai run di training; le serie temporali alimentano dashboard di servizio.
3. Per i KPI di governance: combinazione di evidenze dal SIEM (per audit log e incidenti), dal model registry (per coverage model card e bias review) e dal sistema di ticketing (per findings di audit).

PRINCIPIO

Un KPI che richiede intervento manuale ogni mese per essere aggiornato non è un KPI, è un report. Tutti i target esposti in questa sezione sono pensati per essere calcolati e visibili in tempo quasi-reale dal sistema, non riassunti a posteriori.

10. Conclusioni e raccomandazioni strategiche

Il documento ha argomentato che per Energogrid la risposta corretta al problema della piattaforma AI non è un cloud preferito né un'architettura single-vendor portata all'estremo. È una architettura ibrida costruita per assegnare ogni workload al cluster di soluzioni dove la sua intersezione di vincoli (di sovranità, latenza, volume, costo, integrazione) rende l'opzione dominante. La complessità che ne consegue è un costo reale, non un vezzo, e va gestito esplicitamente attraverso governance, automazione e disciplina di lock-in. In cambio, la flessibilità operativa, la resilienza ai cambi di scenario regolatorio e la riduzione del rischio tecnologico giustificano la scelta.

10.1 Sintesi delle scelte strategiche

Dimensione strategica	Scelta raccomandata	Motivazione sintetica
Architettura complessiva	Hybrid multi-cloud disciplinato	Massimizza adempimento dei requisiti regolatori e flessibilità operativa, evita il full multi-cloud replicato

Spina dorsale ML	AWS SageMaker per workload elastici, OSS on-prem per sensibili	Maturità della piattaforma, ecosistema, integrazione IoT industriale
Analytics su grandi volumi	GCP BigQuery + BigQuery ML	Unico provider con warehouse serverless petabyte-scale e training tabellare nativo
LLM enterprise	Azure OpenAI Service in regione EU	Garanzie contrattuali enterprise, integrazione Office 365, compliance certificata
Componenti sensibili	OSS on-prem (Kubernetes + MLflow + FastAPI)	Sovranità dato, latenza, controllo del codice per audit, riduzione lock-in
Identità e accessi	Federazione cross-cloud su Entra ID	Single source of truth, separazione IT-OT, MFA obbligatorio
Osservabilità	Prometheus + Grafana come base, integrazione provider-specific complementare	Layer OSS portabile, copre cloud e on-prem in modo omogeneo
Lifecycle ML	MLflow come registry unico, cross-cluster	Standard de facto, indipendente da provider, abilita la portabilità

10.2 Priorità raccomandate

Le tre priorità di intervento per i prossimi 12 mesi, in ordine di criticità rispetto al successo del programma.

1. Costruire la fondazione di governance prima dell'infrastruttura. IAM federato, model registry, classificazione dato e quadro normativo vanno definiti e operativi entro M6, perché costruire ML su una governance traballante moltiplica il debito tecnico futuro.
2. Investire nel team prima della tecnologia. Una piattaforma ibrida che il team non sa operare diventa un rischio strategico a tutti gli effetti. Hiring senior in wave 1, formazione strutturata, partnership con system integrator solo per accelerare, non per sostituire la capacità interna.
3. Lanciare un solo pilota end-to-end in wave 1, non tre paralleli. Il pilota forecasting (volumi prevedibili, dato meno sensibile) è il candidato migliore perché valida la fondazione tecnica e organizzativa con rischio contenuto, e prepara il terreno per i due casi d'uso più impegnativi.

10.3 Prossimi passi strategici

Sul fronte decisionale, due valutazioni vanno chiuse nei prossimi 90 giorni perché bloccano l'avvio operativo: selezione del cloud primario fra AWS e Azure (la consegna raccomanda AWS sulla base della maturità ML, ma una valutazione specifica dei contratti enterprise esistenti può invertire la raccomandazione), e definizione formale del modello di ownership cross-funzionale fra IT, OT, ML e Compliance.

Sul fronte operativo, tre azioni preparano la wave 1: kickoff del program management con sponsorship esecutiva esplicita, ingaggio di un partner di sistema per accelerare la landing zone e il primo cloud, avvio del piano hiring per le quattro figure senior identificate nella [sezione 6.1](#).

Sul fronte istituzionale, l'apertura formale del dialogo con il regolatore (ARERA per il mercato italiano, ACER a livello europeo) e con l'autorità competente NIS2 va anticipata. Comunicare il

programma in fase di disegno è meno costoso che subire un'ispezione su un sistema già in produzione.

CHIUSURA

L'AI nel settore energetico non è una corsa tecnologica: è una trasformazione operativa che ha l'AI come abilitatore. La piattaforma raccomandata in questo documento non è best-in-class su nessun singolo asse; è la combinazione che meglio bilancia i vincoli che Energogrid affronta nei prossimi cinque anni. La revisione periodica di questa scelta, a ogni gate, è la disciplina che la mantiene rilevante.

Allegato A · Glossario

Termine	Definizione
AlaaS	AI-as-a-Service. Modello di consumo di capacità AI come servizio cloud, fatturato a consumo.
ARERA	Autorità di Regolazione per Energia Reti e Ambiente, regolatore italiano del mercato elettrico e gas.
AutoML	Categoria di servizi che automatizzano la selezione di algoritmo e iperparametri su dati strutturati.
Azure ML	Azure Machine Learning. Piattaforma Microsoft per il ciclo di vita ML.
Azure OpenAI	Servizio Azure che espone i modelli OpenAI sotto contratto enterprise con garanzie di non-training e residency.
BigQuery	Data warehouse serverless e columnar di Google Cloud, fatturato per byte scansionati.
CapEx / OpEx	Capital Expenditure (investimento ammortizzato) vs Operating Expenditure (costo operativo corrente).
CT	Continuous Training. Pratica MLOps di retraining automatico su trigger di drift o cadenza.
Data lineage	Tracciabilità del percorso di un dato dalla sorgente fino al consumo, attraverso le trasformazioni intermedie.
Data sovereignty	Vincolo regolatorio che impone la residenza del dato in una giurisdizione specifica.
Drift	Cambiamento della distribuzione dei dati di input (data drift) o della relazione fra input e target (concept drift).
EU AI Act	Regolamento UE 2024/1689 sulla intelligenza artificiale, applicabile per fasi dal 2025.
Feature store	Repository centralizzato di feature ML, con definizioni condivise fra training e serving.
FastAPI	Framework Python per la realizzazione di API REST asincrone con tipizzazione forte e OpenAPI nativo.
FinOps	Disciplina di gestione finanziaria del cloud (governance del consumo, ottimizzazione, accountability).
GDPR	Regolamento UE 2016/679 sulla protezione dei dati personali.
HIL	Human-in-the-loop. Supervisione umana sulle decisioni di un sistema automatico.
Hybrid	Architettura che combina modelli di servizio diversi (PaaS, IaaS, OSS) o cloud diversi.
IaaS	Infrastructure-as-a-Service. Modello cloud in cui il provider fornisce risorse infrastrutturali (compute, storage, rete).
IEC 62443	Standard di cybersecurity per industrial automation and control systems.
ISO 27001	Standard internazionale per sistemi di gestione della sicurezza delle informazioni (ISMS).
ISO 27019	Estensione settoriale di ISO 27001 per il settore dell'energia.
Lock-in	Costo e attrito di sostituire un fornitore con un altro; più alto in PaaS proprietari, più basso in OSS.
MLflow	Piattaforma open source per experiment tracking, model registry e gestione del lifecycle ML.
MLOps	Disciplina che applica i principi DevOps al ciclo di vita ML (CI, CD, CT, monitoring).
MTBF	Mean Time Between Failures. Indicatore di affidabilità degli asset.

MAPE	Mean Absolute Percentage Error. Metrica di errore relativo per modelli di forecasting.
NIS2	Direttiva UE 2022/2555 sulla sicurezza delle reti e dei sistemi informativi, recepita in Italia nel 2024.
OPC UA	Open Platform Communications Unified Architecture. Protocollo standard di comunicazione industriale.
OSS	Open Source Software.
OT	Operational Technology. Sistemi di automazione industriale e controllo di processo, distinti dall'IT tradizionale.
PaaS	Platform-as-a-Service. Modello cloud in cui il provider gestisce la piattaforma applicativa, il consumer porta solo il codice e i dati.
PII	Personally Identifiable Information.
Prosumer	Utente che è contemporaneamente consumatore e produttore di energia (tipicamente fotovoltaico domestico).
RAG	Retrieval-Augmented Generation. Pattern di LLM che attinge a una base di conoscenza esterna durante l'inferenza.
RACI	Modello di riferimento per le responsabilità (Responsible, Accountable, Consulted, Informed); la matrice della sezione 5.4 ne adotta una variante semplificata.
RPO / RTO	Recovery Point Objective / Recovery Time Objective. Metriche di disaster recovery.
SageMaker	Piattaforma ML end-to-end di AWS.
SCADA	Supervisory Control And Data Acquisition. Sistema di supervisione e controllo dei processi industriali.
Spot / preemptible	Istanze cloud a costo ridotto ma con possibilità di revoca; adatte a workload tolerant a interruzione.
Substation	Sottostazione elettrica. Nodo di trasformazione e smistamento sulla rete.
TCO	Total Cost of Ownership. Costo complessivo di possesso di un sistema su un orizzonte definito.
Vertex AI	Piattaforma ML end-to-end di Google Cloud.
Zero trust	Modello di sicurezza che non assume fiducia implicita interna alla rete; ogni accesso è verificato esplicitamente.

Allegato B · Riferimenti normativi

Riferimenti normativi citati nel documento. Le voci sono elencate con riferimento ufficiale per consentire la verifica.

Riferimento	Titolo	Ambito
Reg. UE 2016/679 (GDPR)	Regolamento generale sulla protezione dei dati	Dati personali, trattamento, residency
Dir. UE 2022/2555 (NIS2)	Direttiva sulla sicurezza delle reti e dei sistemi informativi	Cybersecurity per operatori essenziali; recepimento Italia D.Lgs. 138/2024
Reg. UE 2024/1689 (AI Act)	Regolamento sulla intelligenza artificiale	Sistemi AI ad alto rischio, gestione, trasparenza, supervisione umana
ISO/IEC 27001:2022	Information security management systems - Requirements	ISMS aziendale (baseline)
ISO/IEC 27019:2024	Information security controls for the energy utility industry	Estensione settore energia per ISO 27001
ISO/IEC 27017:2015	Code of practice for information security controls based on ISO/IEC 27002 for cloud services	Controlli cloud-specific
ISO/IEC 27018:2019	Code of practice for protection of PII in public clouds	Protezione PII in cloud pubblici
IEC 62443 serie	Industrial communication networks - Network and system security	Cybersecurity OT/ICS (zone, conduit, security level)
IEC 60870-5-104	Telecontrol equipment and systems - Network access for IEC 60870-5-101	Protocollo SCADA su TCP/IP
IEC 61850	Communication networks and systems for power utility automation	Standard di comunicazione in substation
Linee guida ENISA	Cloud Security guidance for the Energy Sector	Best practice di sicurezza cloud per settori essenziali
Direttiva (UE) 2019/944	Norme comuni per il mercato interno dell'energia elettrica	Mercato elettrico UE, customer empowerment, smart metering

Le normative evolvono. La data di riferimento per le scelte di questo documento è luglio 2026. Aggiornamenti delle norme (ad esempio l'adozione progressiva degli atti delegati dell'AI Act) vanno presidiati con cadenza almeno semestrale dalla funzione Governance & Compliance.